BUSCA ON-LINE

ALGORITMOS ON-LINE DFS E LRTA*

Prof. Tacla UTFPR/Curitiba

Off-line vs. On-line

Na busca off-line o agente primeiro computa toda a sequência de ações para então executá-la no ambiente.

Na busca on-line, o agente intercala computação e ação:

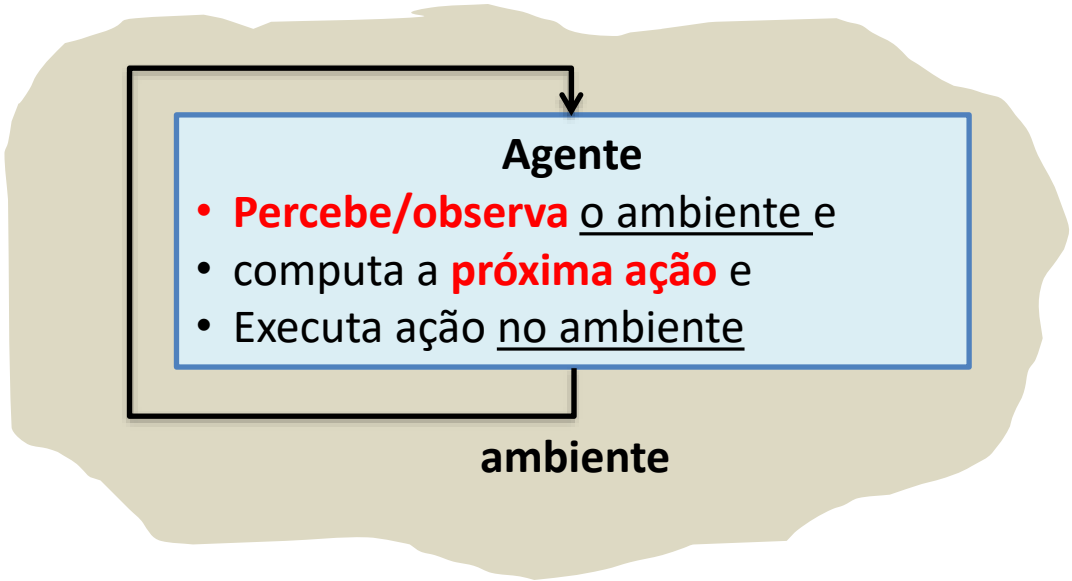

Malha-fechada: o agente utiliza as percepções para saber em qual estado se encontra

Aplicações

aplicável em **ambientes dinâmicos e semi-dinâmicos**

(nestes últimos, há penalidade quando se toma muito tempo para deliberar)

interessante para **ambientes não-determinísticos** pois o agente pode focar em contigências que realmente acontecem ao invés de considerar todas que *podem* acontecer (como no caso da busca em grafo and-or)

aplicáveis **em problemas de exploração**:

- agente não conhece a topografia do ambiente (ou um mapa do ambiente)
- Agente não conhece o resultado de suas ações no ambiente

Expansão de nós vizinhos

A* pode expandir um nó em uma região do espaço de estados e, em seguida, em outra região completamente diferente.

Já um algoritmo online somente consegue descobrir sucessores de **um nó no qual ele está fisicamente** – *um robô não pode desaparecer de um lugar e aparecer em outro* - então, a ideia é expandir nós próximos para evitar retornos físicos.

A busca em profundidade expande sempre um nó filho do anterior (exceto quando faz *backtracking*)

BUSCA ON-LINE

BUSCA EM PROFUNDIDADE ON-LINE (ON-LINE DFS)

Busca em Profundidade on-line

Funções principais do algoritmo:

ACTIONS(s)
retorna as ações possíveis de serem executadas no estado s; em princípio, todas as ações

RESULT(s, a)
armazena a função sucessora aprendida durante a exploração e retorna o estado sucessor de *s* pela execução de *a* (se conhecido)

UNTRIED(s)
Lista de ações ainda não tentadas no estado s

UNBACKTRACKED(s)
Lista de ações ainda não desfeitas no estado s

Exemplo 1: on-line DFS

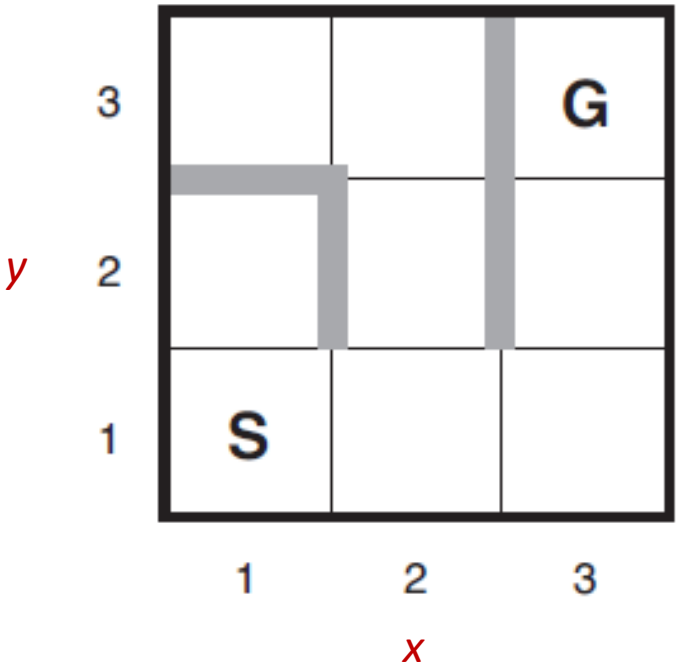

Robô inicia em S e deve atingir G
Não conhece a topografia do ambiente
Não conhece o efeito de suas ações
Tem um sensor que permite goal-test
Ações = **{Right, Up, Down, Left}**

Exemplo 1: on-line DFS

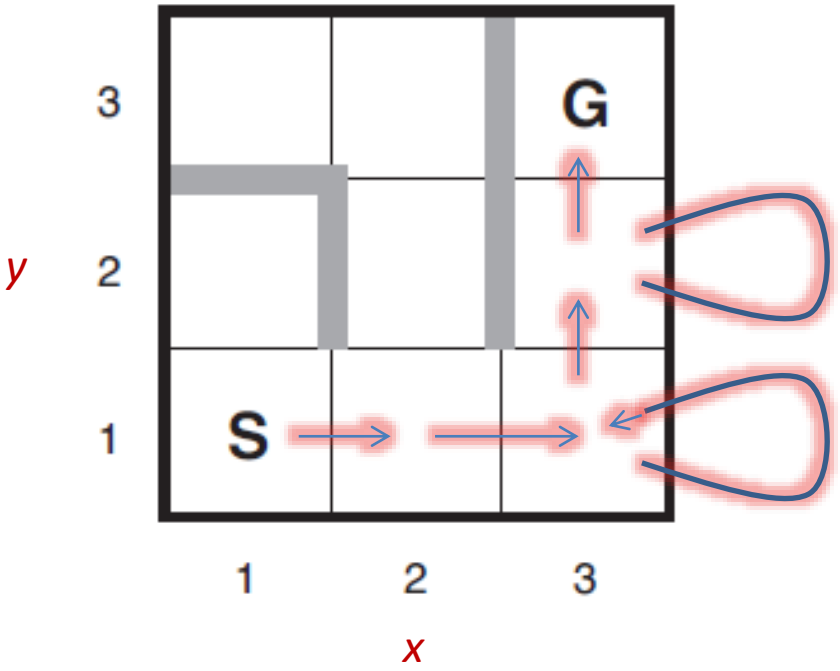

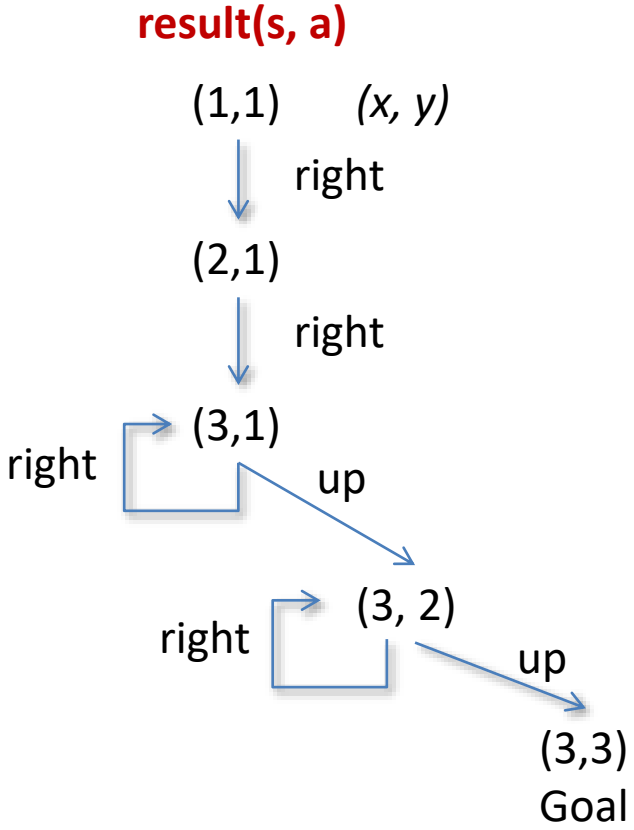

Ações = **Right > Up > Down > Left**

Função sucessora aprendida durante a execução

Exercício 1a: on-line DFS

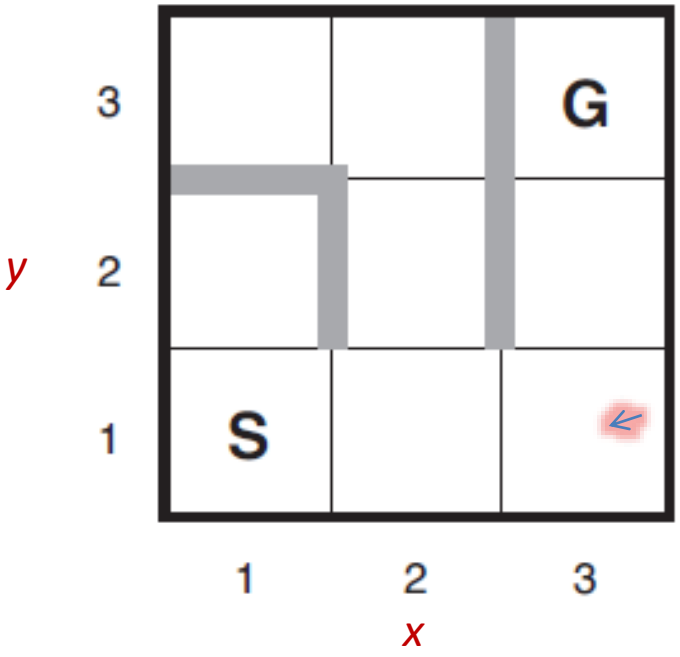

Qual seria a função RESULT(S,a) após a execução para esta ordenação de ações?

Qual seria a função UNTRIED(s) após a execução para esta ordenação de ações?

Ações = **UP > RIGHT > Down > Left**

Exemplo 2: on-line DFS com backtracking

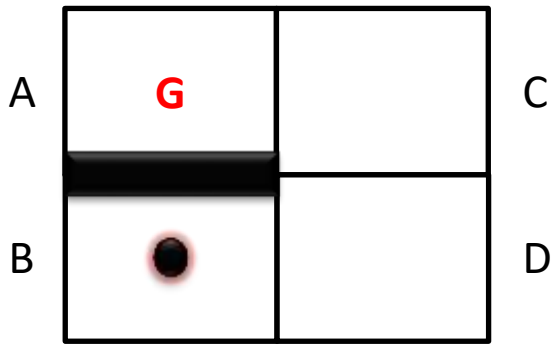

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B = U>D>R>L
C = U>D>R>L
D = U>D>R>L
```

Result(s, a) -> s'

```
  U  D  R  L
A
B
C
D
```

Exemplo 2 on-line DFS: com backtracking

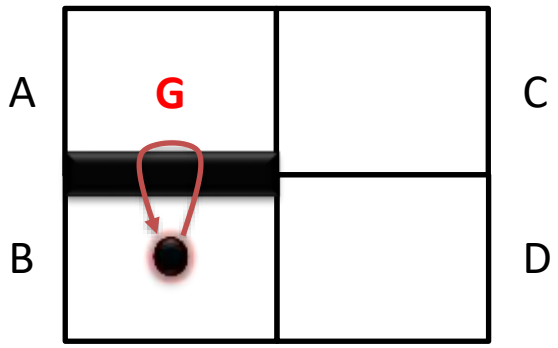

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =   D>R>L
C = U>D>R>L
D = U>D>R>L
```

Result(s, a) -> s'

estados	U	D	R	L
A				
B	**B**			
C				
D				

Exemplo 2 on-line DFS: com backtracking

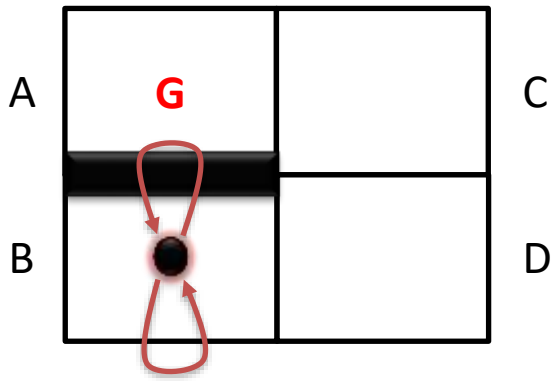

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =     R>L
C = U>D>R>L
D = U>D>R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**		**B**	
C				
D				

Exemplo 2 on-line DFS: com backtracking

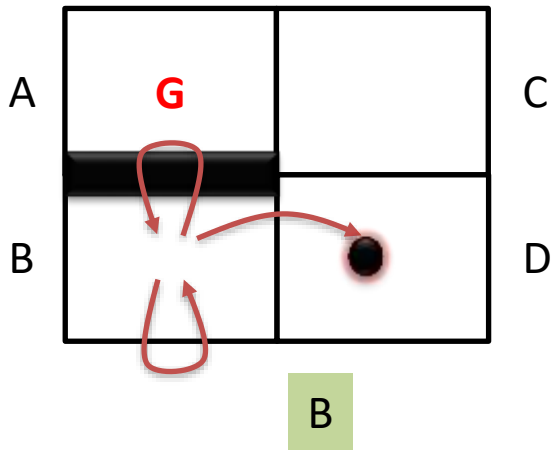

Unbacktracked associado ao estado **em(D)**

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =      >L
C = U>D>R>L
D = U>D>R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C				
D				

Exemplo 2 on-line DFS: com backtracking

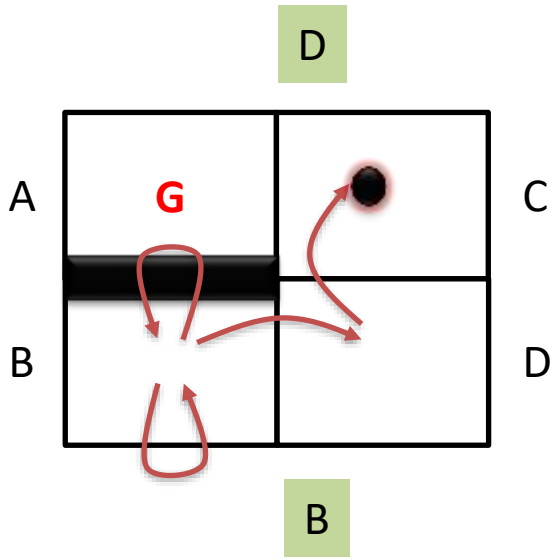

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =      >L
C = U>D>R>L
D =  >D>R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C				
D	**C**			

Exemplo 2 on-line DFS: com backtracking

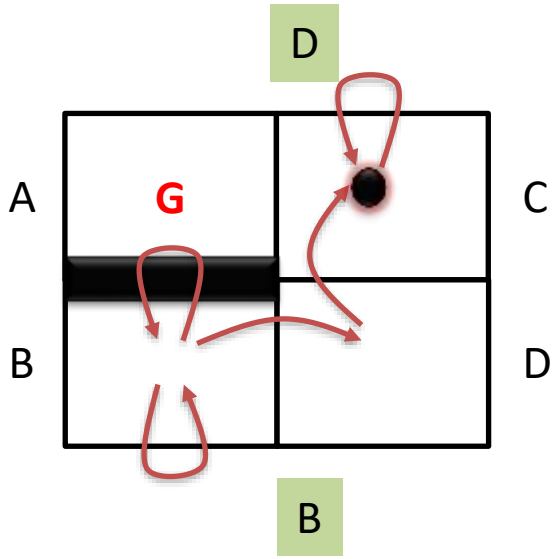

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =      >L
C =  >D>R>L
D =  >D>R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C	**C**			
D	**C**			

Exemplo 2 on-line DFS: com backtracking

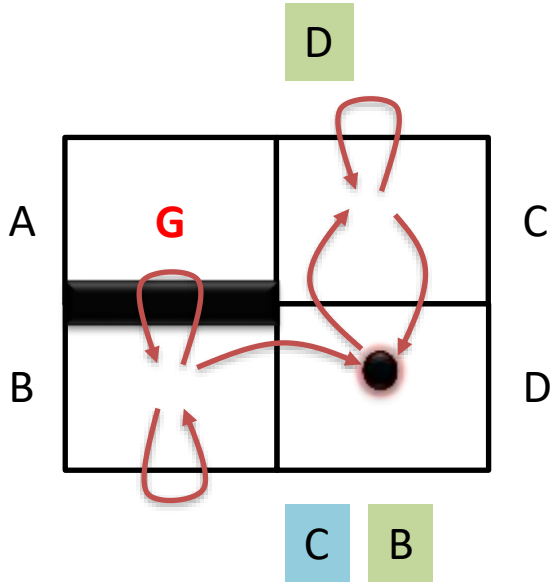

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =       >L
C =     >R>L
D =   >D>R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C	**C**	**D**		
D	**C**			

Exemplo 2 on-line DFS: com backtracking

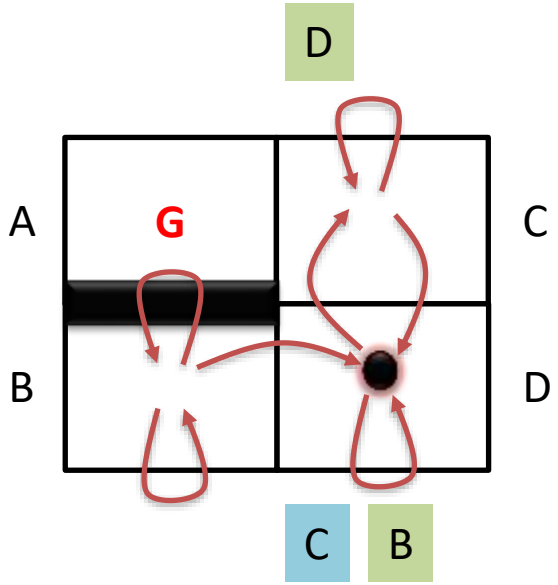

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =      >L
C =    >R>L
D =    >R>L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C	**C**	**D**		
D	**C**	**D**		

Exemplo 2 on-line DFS: com backtracking

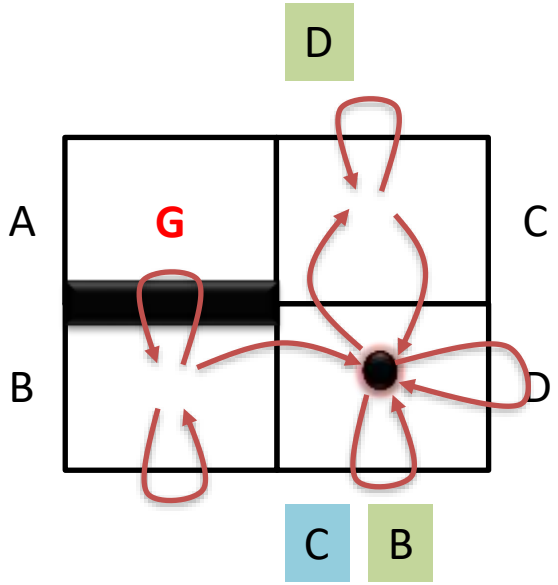

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =       >L
C =     >R>L
D =       >L
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C	**C**	**D**		
D	**C**	**D**	**D**	

Exemplo 2 on-line DFS: com backtracking

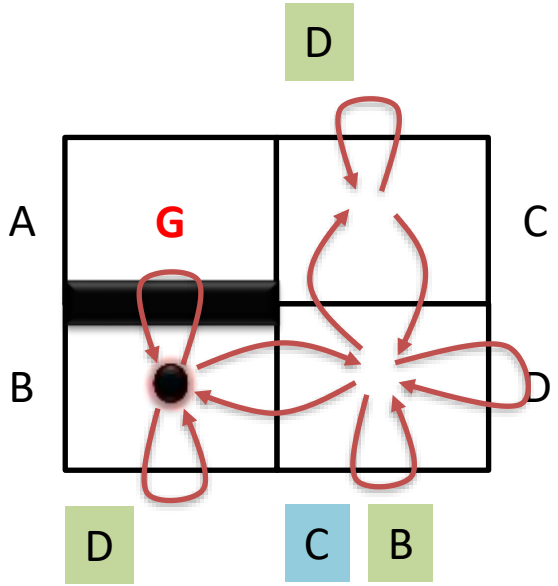

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =      >L
C =    >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Exemplo 2 on-line DFS: com backtracking

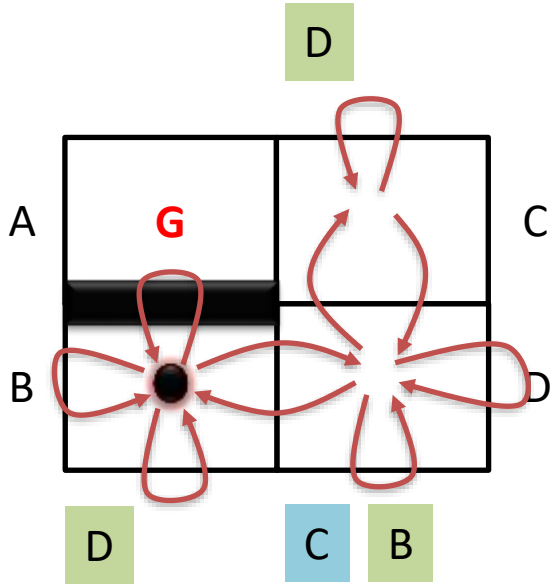

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =    >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Exemplo 2 on-line DFS: com backtracking

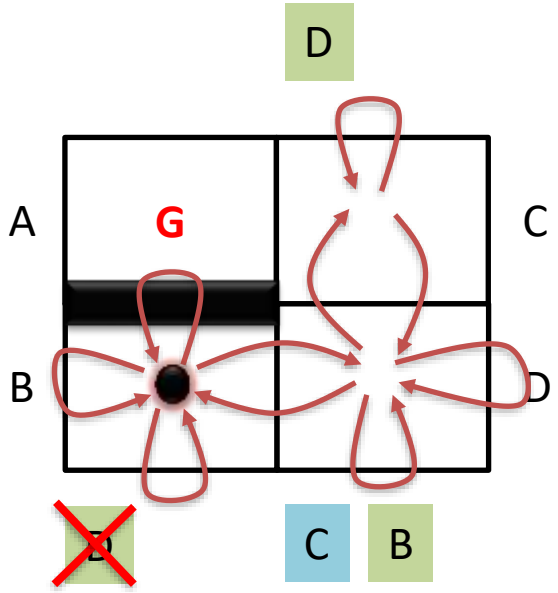

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =    >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Não há mais ações a testar no estado **em(B).**

Pop (unbacktracked (B)) → vai para estado D
(i.e. executa a ação que leva o agente ao estado D = right)

Exemplo 2 on-line DFS: com backtracking

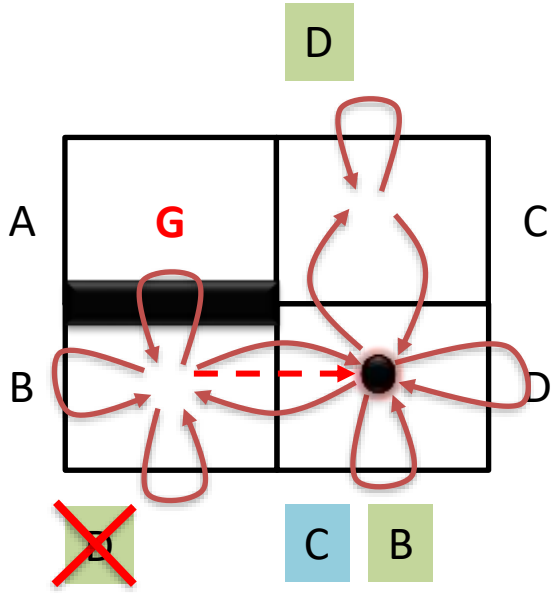

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =     >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Não há mais ações a testar no estado **em(B).**

Pop (unbacktracked (B)) → vai para estado D
(i.e. executa a ação que leva o agente ao estado D = right)

Exemplo 2 on-line DFS: com backtracking

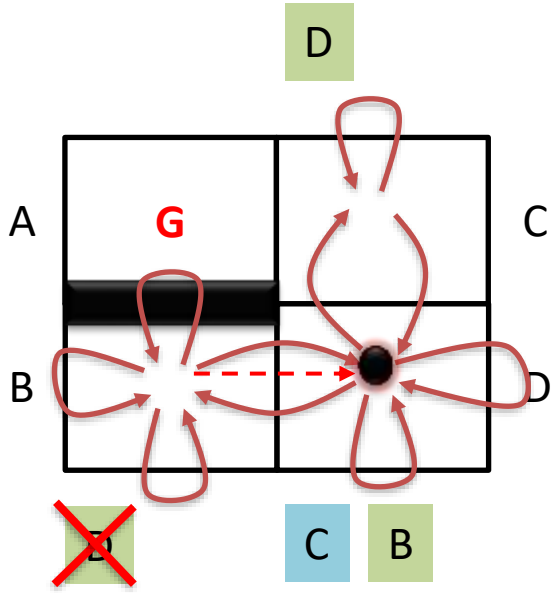

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =    >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Não há mais ações a testar no estado **em(D).**

Exemplo 2 on-line DFS: com backtracking

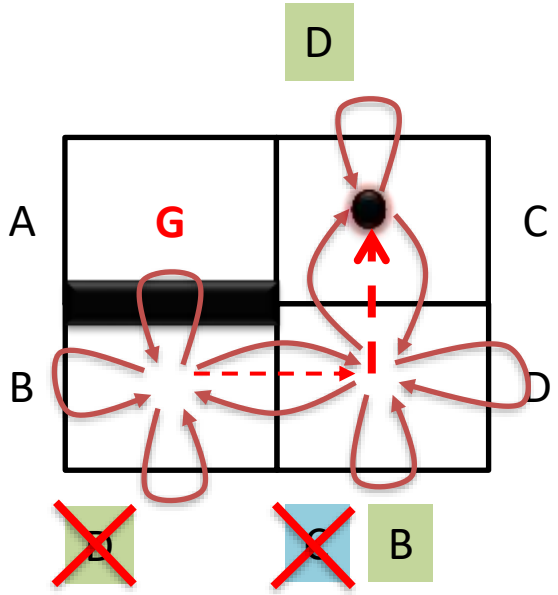

Estados S= {A, B, C, D}
S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =    >R>L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**		
D	**C**	**D**	**D**	**B**

Não há mais ações a testar no estado **em(D).**
Pop(unbactracked(D)) → VAI para estado C
(i.e. executa a ação que leva o agente ao estado C = UP)

Exemplo 2 on-line DFS: com backtracking

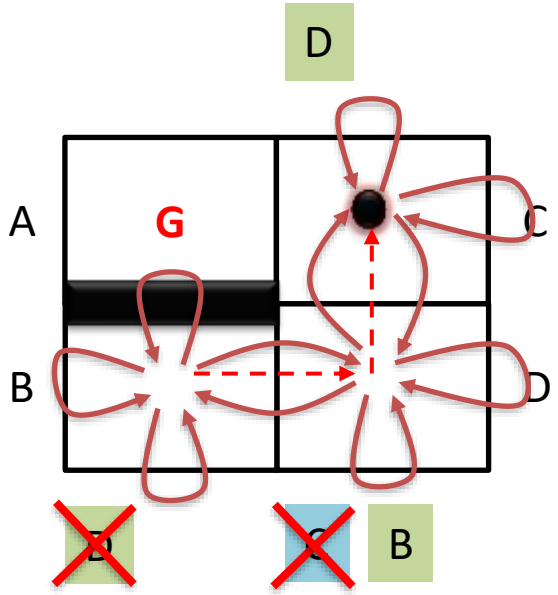

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =       >L
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**	**C**	
D	**C**	**D**	**D**	**B**

Exemplo 2 on-line DFS: com backtracking

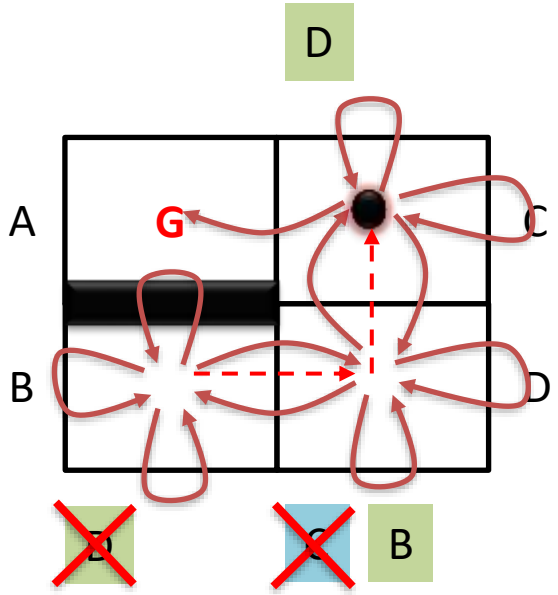

Estados S= {A, B, C, D}

S_0 = B, s_g = A

Ações = {Up, Down, Right, Left}

Untried

```
A = U>D>R>L
B =
C =
D =
```

Result(s, a) -> s'

	U	D	R	L
A				
B	**B**	**B**	**D**	**B**
C	**C**	**D**	**C**	**A**
D	**C**	**D**	**D**	**B**

Busca em Profundidade (DFS) online

```
function ONLINE-DFS-AGENT(s') returns an action
  inputs: s', a percept that identifies the current state
  persistent: result, a table indexed by state and action, initially empty
              untried, a table that lists, for each state, the actions not yet tried
              unbacktracked, a table that lists, for each state, the backtracks not yet tried
              s, a, the previous state and action, initially null

  if GOAL-TEST(s') then return stop
  if s' is a new state (not in untried) then untried[s'] ← ACTIONS(s')
  if s is not null then
      result[s, a] ← s'
      add s to the front of unbacktracked[s']
  if untried[s'] is empty then
      if unbacktracked[s'] is empty then return stop
      else a ← an action b such that result[s', b] = POP(unbacktracked[s'])
  else a ← POP(untried[s'])
  s ← s'
  return a
```

Função sucessora aprendida durante execução

If I've already seen the result of this [s, a] then don't put it back on the unbacktracked list otherwise you can keep oscillating between the same states endlessly.

Online DFS

O online DFS funciona bem para ambientes estáticos onde o agente não conhece o efeito de suas ações no ambiente.

Este algoritmo só funciona em espaços de estados onde as **ações são reversíveis**.

Irreversibilidade das ações é provocada pela própria incapacidade do agente (ex. agente que somente executa UP e RIGHT) ou por ambiente dinâmico (ex. paredes que se fecham atrás do agente)

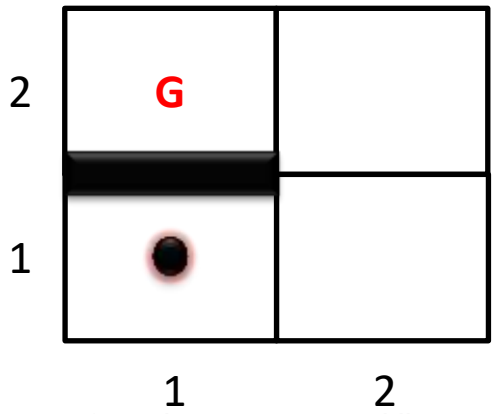

BUSCA ON-LINE

LRTA*

LRTA* ou ATRA*

Learning real-time A* (Korf, 1990)

chamado de ATRA* em português

Recorda-se que lidamos com situações onde é mais importante agir razoavelmente **em tempo hábil** (intercalando raciocínio e ação) do que minimizar o custo de execução tendo que passar muito tempo para encontrar uma solução (planejando).

LRTA* Learning real-time A* (Korf, 1990)

ideia:equilibrar o tempo de **planejamento** e **execução**

Exemplos:
personagem de games: inverossímil se ficar sentado numa pedra calculando o caminho mínimo e depois executá-lo rapidamente.

carro automático: calcular a trajetória ótima em um curva – antes de acabar o cálculo terá batido!

Korf, 1990. Real-time heuristic search. Artificial Intelligence, 42(3), 189-212

LRTA* Learning real-time A* (Korf, 1990)

Cenário: problema de navegação **em um terreno conhecido**; o agente sabe onde está inicialmente; ambiente semi-dinâmico = penalidade por demora na deliberação.

Ações do robô:
Norte, Leste, Sul ou Oeste

Custo das ações: 1

Inicialização da h(n): distância de Manhattan (e.g. f(C1) = 3)

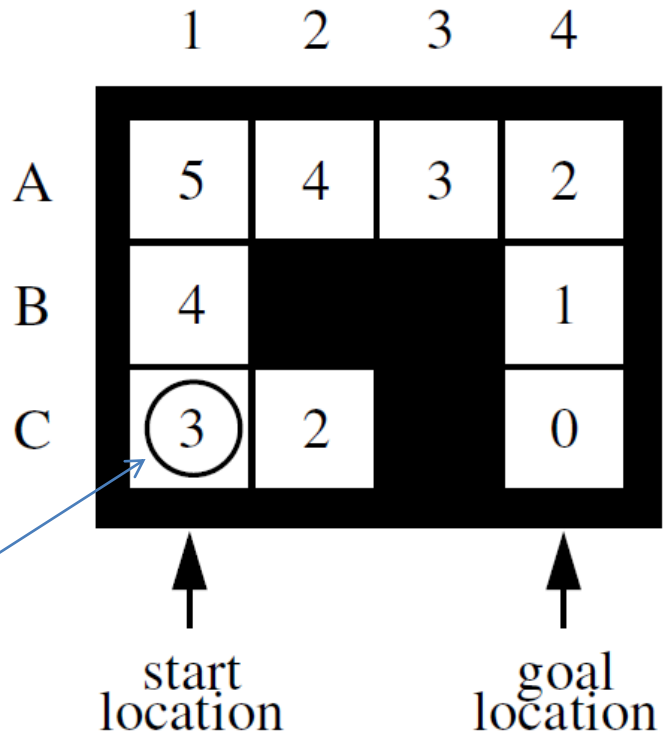

(Koenig, 2001. Agent Search, AI Magazine, 109-132)

LRTA*

f(n) inicial para todos os estados

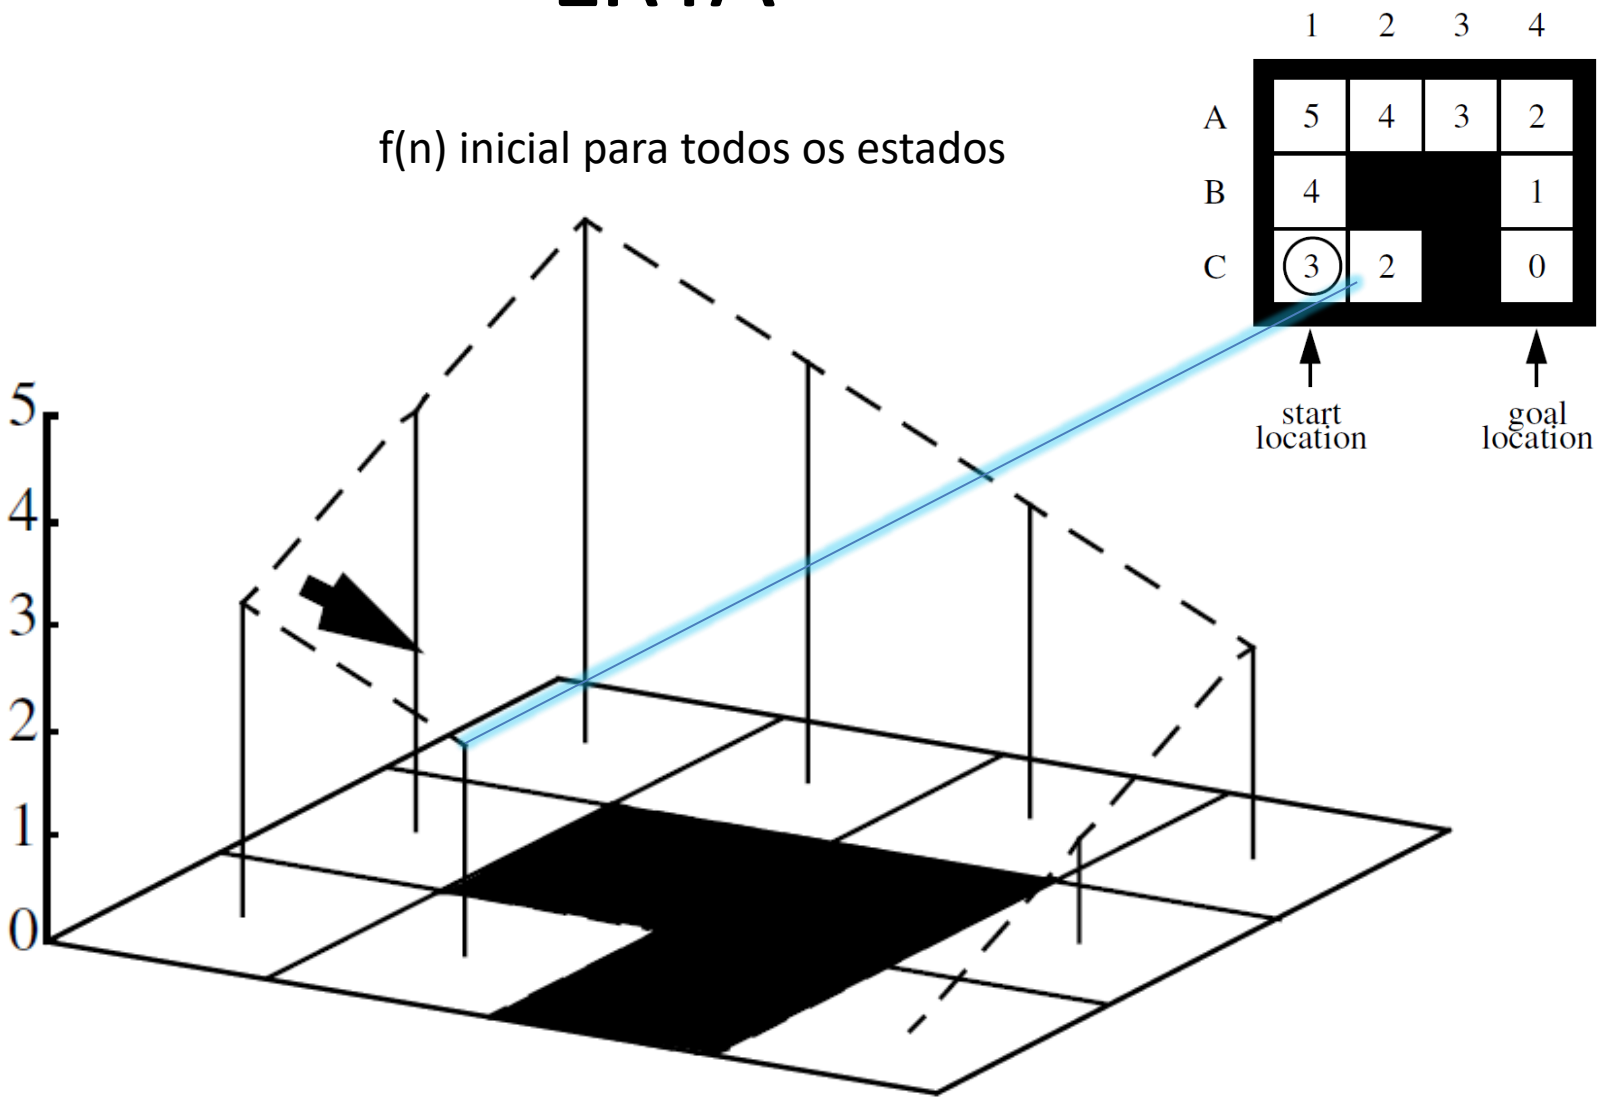

Numa busca gulosa, o robô fica preso em C1 e C2

(Koenig, 2001)

LRTA*

LRTA* escapa dos mínimos locais aumentando o valor de f(n) 'enchendo' os mínimos locais na superfície de valores

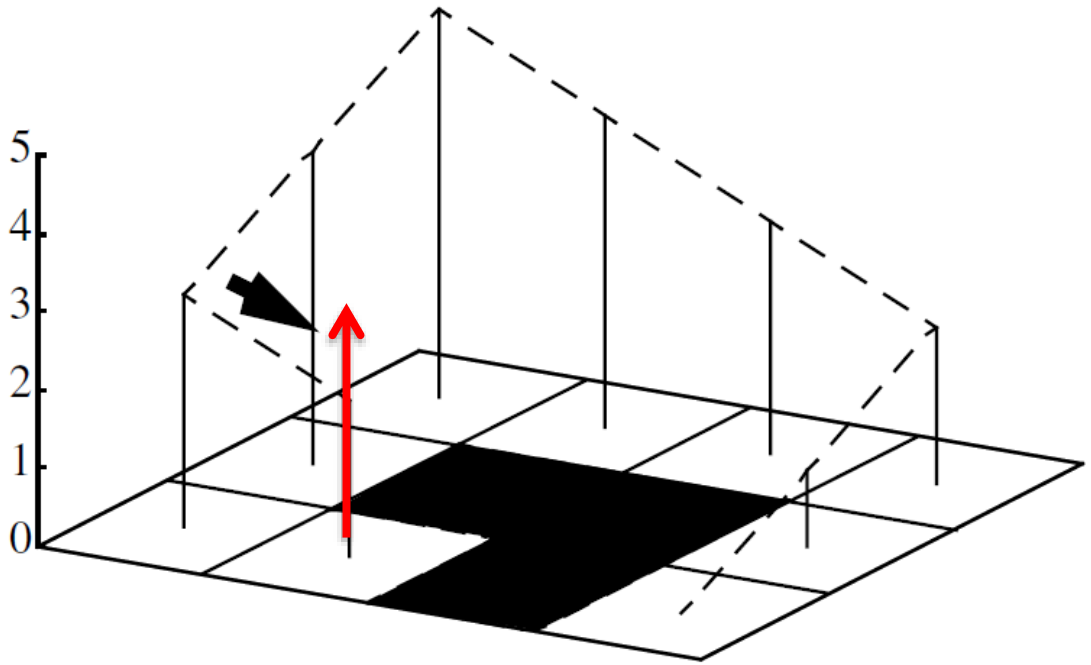

(Koenig, 2001)

LRTA*: intuição

n = estado corrente
n‘ = representa um estado vizinho qualquer

Para cada ação <a> no estado corrente <n>,
calcule para todo vizinho de <n> chamado n’:

f(n’) = c(n, a, n’) + h(n’)

Atualizar custo estimado nó n: **$h(n) \leftarrow \min_n, f(n')$**

Escolher a ação **<a>** que leva ao vizinho n’ de menor f(n’); em caso de empate, escolha randomicamente.

LRTA*: EXEMPLO

Ações: NORTE, SUL, LESTE, OESTE

Custo das ações é uniforme = 1

Amarelo:	estado atual = n
Vermelho:	estado objetivo
Azul:	avaliação dos nós vizinhos = n'
	valores nas casas azuis são temporários
	f(n') = c(n, a, n') + h(n')

Empates decididos randomicamente

Estados são inicializados com o valor de h(n) (valores na matriz)
Ao longo da execução, h(n) é atualizado.

LRTA*: EXECUÇÃO 1

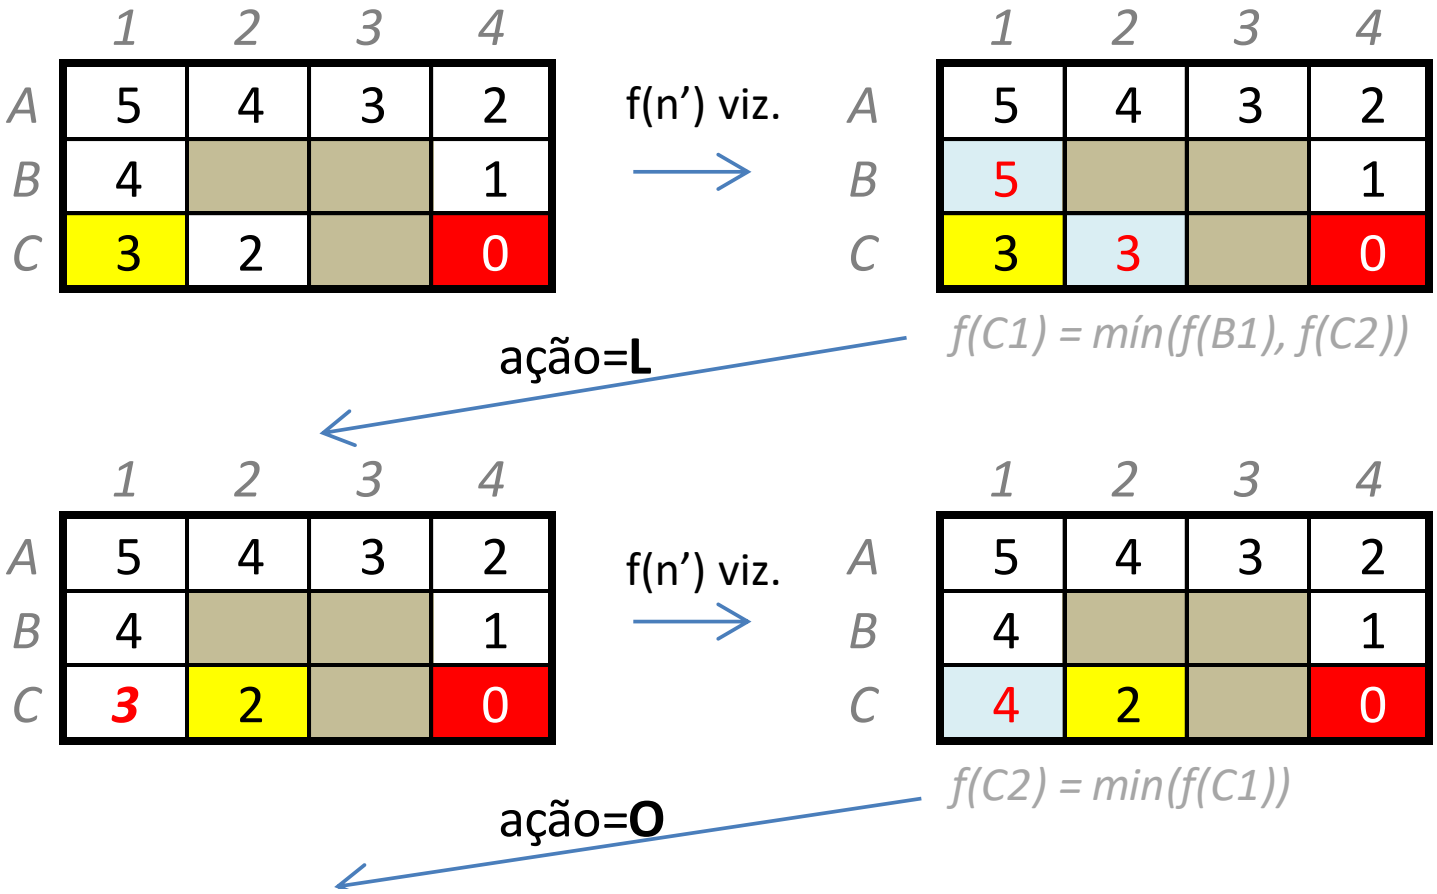

LRTA*: EXECUÇÃO 1

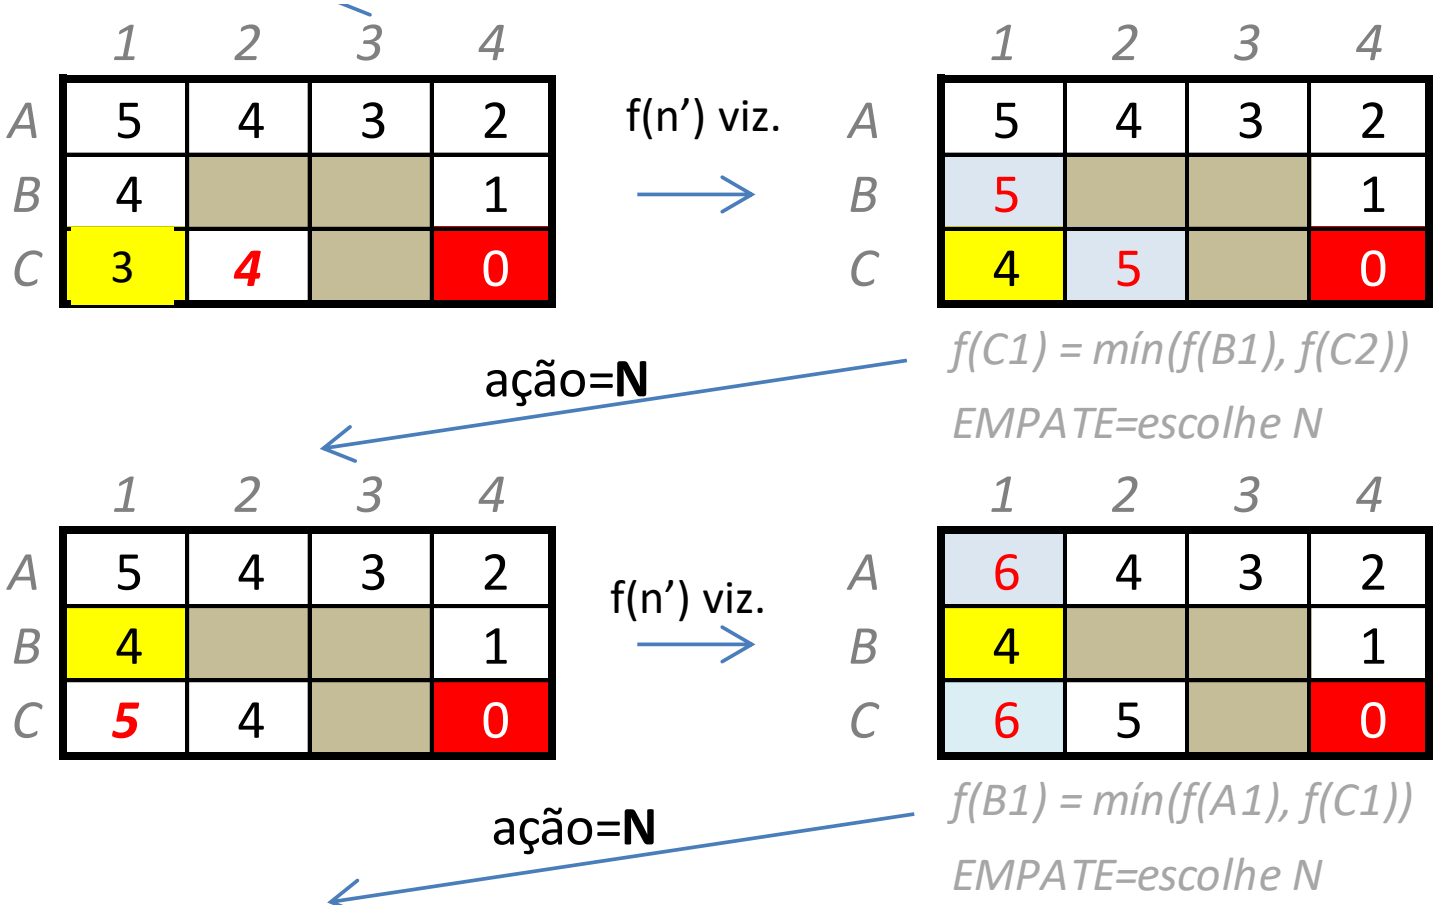

LRTA*: EXECUÇÃO 1

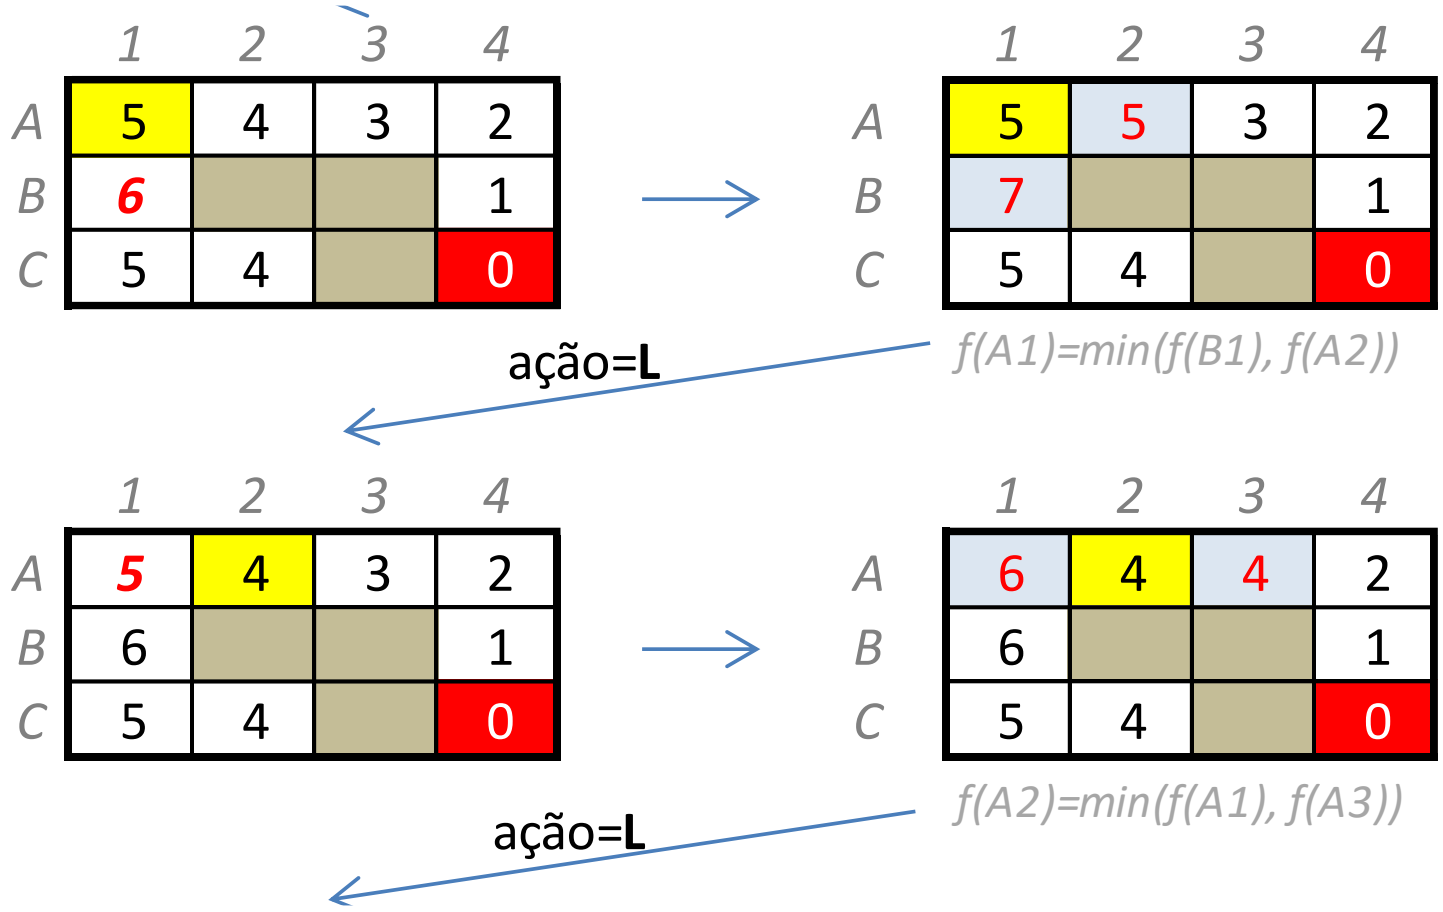

LRTA*: EXECUÇÃO 1

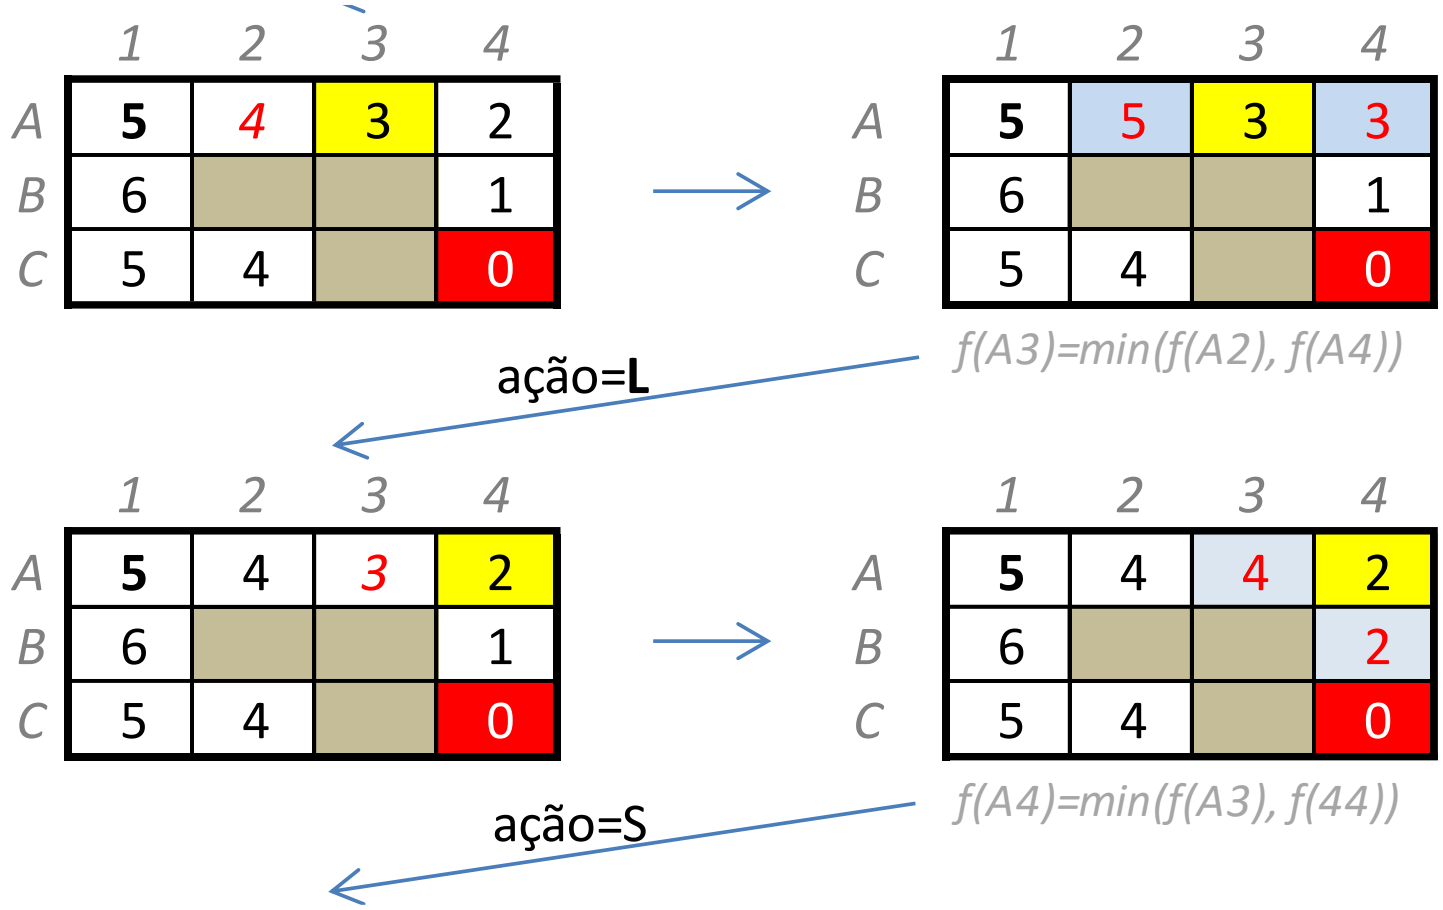

LRTA*: EXECUÇÃO 1

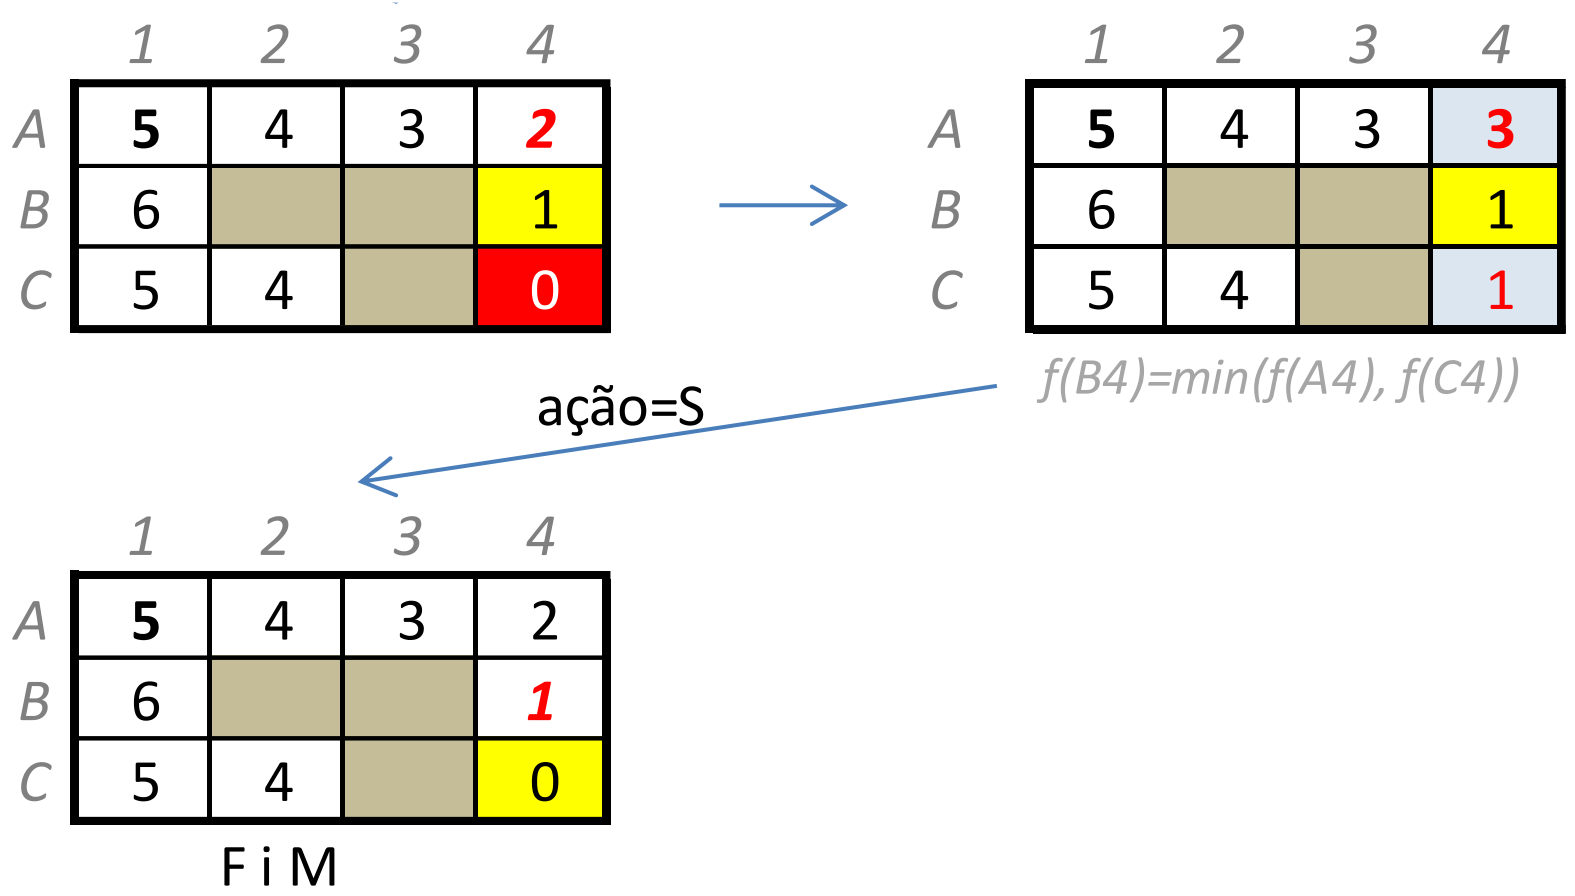

LRTA*: EXECUÇÃO 1

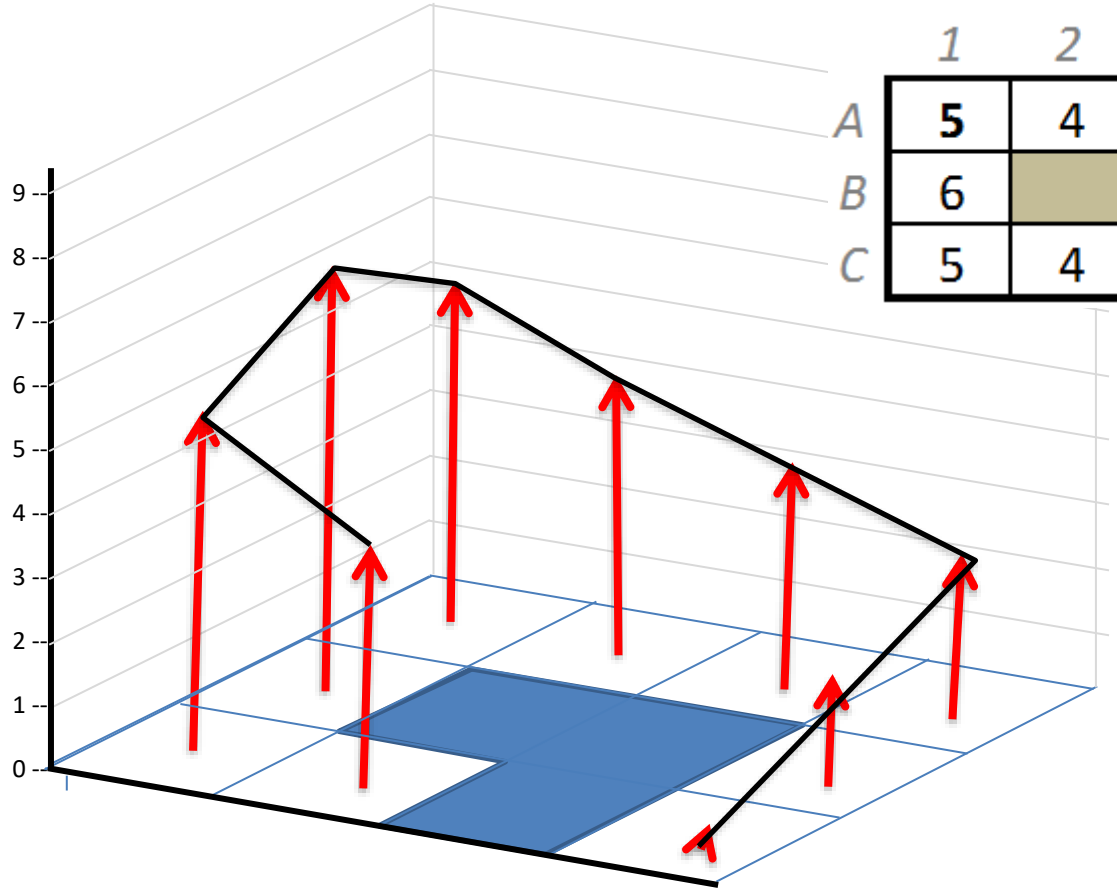

	1	2	3	4
A	**5**	4	3	2
B	6			***1***
C	5	4		0

(Koenig, 2001)

LRTA*: EXECUÇÃO 2

	1	2	3	4
A	**5**	4	3	2
B	6			***1***
C	7	6		0

F i M

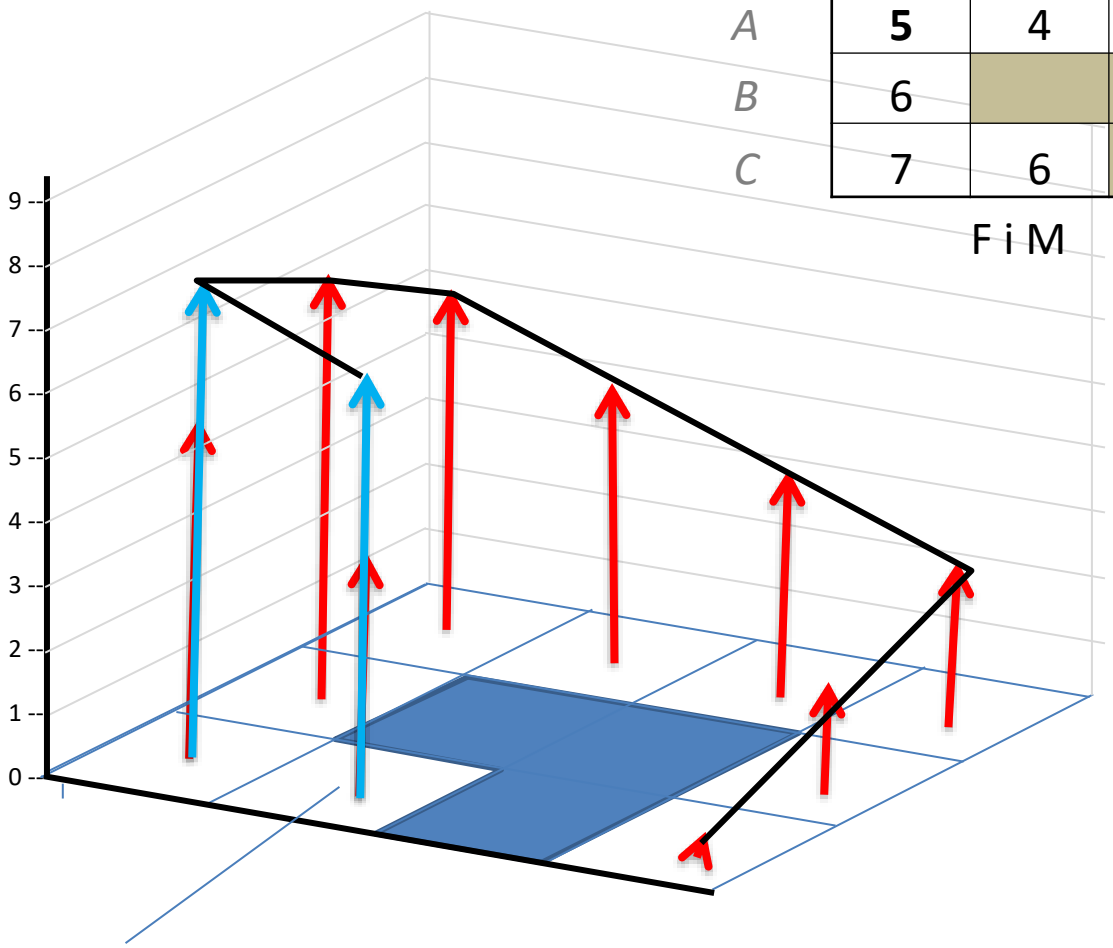

com mais execuções, o valor da posição C2 atingiria 8 que é o custo real

(Koenig, 2001)

LRTA*

Requisito

Valor inicial de h deve ser otimista, i.e.
$h(n) \leq h^*(n)$

LRTA*

O algoritmo é completo?

Sim,

se há um número finito de nós com arestas (ações) de custos positivos, e

se existem caminhos de cada nó ao nó objetivo (*não há nó isolado*) e

se h(n) é não-negativo (pode ser zero)

então LRTA* encontrará o nó objetivo

LRTA*

É ótimo?

Requer várias execuções para alcançar otimalidade.

Se as estimativas iniciais forem admissíveis, então, executando-o várias vezes no mesmo problema, os valores aprendidos pelo LRTA* convergirão para as distâncias reais em todos os caminhos ótimos até o nó objetivo.

quando há empate nos f(n'), a escolha do vizinho deve ser randômica, caso contrário, o algoritmo, ao encontrar uma solução ótima, sempre a seguirá